

ESS 배터리 수명 예측 — 모델 전략 수립 (DAY 1)

DS Mini Project · MIT-Stanford Battery Dataset (Severson et al., Nature Energy 2019)

울산 캠퍼스 1반 · 배재연 | 2026-10-01 | 대상 데이터 : Batch 1 (2017-05-12, 46셀) · Batch 2 (2018-02-20, 47셀) · Batch 3 (2018-04-12, 46셀)

0. 분석 개요


- 목적 : 초기 사이클 데이터만으로 배터리 셀의 수명(cycle_life, 용량 80% 도달 사이클)을 미리 예측 → ESS 교체 비용(CAPEX 30~40%)의 계획적 관리
- 분석 단위 : 배터리 셀 1개 (Y = cycle_life, X = 초기 사이클에서 추출한 피쳐)
- 흐름 : 데이터 품질 점검 → EDA Q1~Q5 (Batch 1 심층) → Batch 1·2·3 비교 → 모델 설계 전략

데이터 품질 점검 (전 분석 공통 전처리)

점검 항목	발견 내용	처리
위장 결측치	isnull() 결측 0개이나, 모든 셀의 cycle 1 측정값이 0으로 기록 (QD·온도·충전시간 46개, IR 65개 — IR은 중간 누락 19개 추가)	cycle 1 및 0값 제외 후 피쳐 계산
이상치	QD 최대 2.884 Ah (정상 약 1.08 Ah), 충전시간 최대 419.9 (평균 11.5)	공칭 용량(중앙값 1.0796 Ah)의 0.8~1.2 배 범위 밖 48행(0.12%) 제거
수명 결측	cycle_life 미기록 셀 : Batch 2 8개, Batch 3 2개	정답이 없으므로 분석·학습에서 제외
분석 단위 왜곡	사이클 행 기준 평균 수명 884 vs 셀 기준 845 (오래 산 셀이 과대 반영)	수명 통계는 셀당 1행으로 계산

※ 0값을 제거하지 않으면 통계량이 왜곡됨 : 원본 코드의 EOL 기준선이 0.76 Ah로 잘못 표시되고(Q2), std_QD=mean_IR의 가짜 상관 0.47이 발생함(제거 후 0.02, Q5).

Q1. Cycle Life 분포는 어떻게 생겼는가?



[그림 1] Batch 1 cycle_life 히스토그램(좌) · 박스플롯(우), n = 46

[describe]

- 평균 844.7 / 중앙값 858.5 / 표준편차 184.6 / 범위 534 ~ 1,227 → 평균 < 중앙값이나 차이가 작아 약한 왼쪽 치우침 수준
- $IQR = 914.2 - 703.2 = 211.0$ → 셀의 절반이 703~914 사이클에 집중. 이상치 경계($1.5 \times IQR$) 386.7 ~ 1,230.7 → 통계적 이상치 없음 (최대 1,227은 경계에 근접)
- 장수명(>1,000) 10개(21.7%) / 단수명(<500) 0개 / 분류 기준(550) 적용 시 단수명 1개 : 장수명 45개


[plot]

- 정규분포가 아닌 세 무리 : 600~800(넓게 분포), 850~900(최빈, 9개), 1,150~1,230(떨어진 5개) → 23종 충전 방식 (방식당 약 2셀)에 따른 그룹화로 추정 (Q4에서 확인)
- 위쪽 수염(313)이 아래쪽(169)보다 김 → 장수명 쪽 편차가 크고 불규칙

[to modeling]

- 학습셋(Batch 1)에 수명 500 미만 셀이 없음 → 단수명 셀을 학습하지 못함 → **테스트 배치 분포 비교 필수** (6장)
- 분류 선택 시 1 : 45의 극심한 불균형 → Accuracy만으로 평가 불가 (회귀/분류 선택 근거)
- 셀 46개 소표본 → 과적합 주의, 단순·정규화 모델 우선

Q2. 열화 곡선 — 방전 용량은 어떻게 감소하는가?



[그림 2] 이상치 제거 후 QD 열화 곡선. 색상 = cycle_life (빨강: 단명, 파랑: 장수)

[describe]

- 공칭 용량(초기 5사이클 중앙값) 1.0796 Ah, EOL = 80% 용량. 이상치 48행 제거
- 초기 100사이클 평균 QD와 수명의 상관 $r = 0.19$ → 약한 관계

[plot]


- 모든 셀이 완만하게 감소하다 급격히 꺾이는 **Knee point** 형태 → 열화 속도가 가속되는 비선형 패턴
- 수명 순서대로 꺾이는 시점이 정렬 : 단명 셀은 400~600, 장수 셀은 800~1,000 사이클부터 급락
- 초기 0~100사이클은 모든 셀이 1.06~1.10 Ah에 겹쳐 **용량 값만으로는 수명 구분 불가**
- 수명 1,150 이상 셀 5개는 EOL에 도달하지 않고 1.02~1.04 Ah에서 기록 종료 → 실험 중단으로 실제 수명보다 짧게 기록되었을 가능성

- 참고 : 원본 코드는 셀 번호 순서로 색을 지정해 "파랑 = 장수" 해석에 근거가 없었음 → 수명 기준 색상으로 재작성하여 확인

[to modeling]

- 초기 용량 값은 예측력이 약함 → 곡선 **형태 변화**를 담은 새 피쳐 필요 (Q3)
- EOL 미도달 의심 셀 5개 → 포함/제외 두 경우로 비교, 데이터 한계로 명시

Q3. $\Delta Q(V)$ 곡선 — 초기 사이클에서 차이가 보이는가?



[그림 3] $\Delta Q(V) = Q_{100}(V) - Q_{10}(V)$ 곡선(좌, 색상 = 수명) · $\log_{10}\text{var}(\Delta Q)$ vs $\log_{10}\text{cycle_life}$ (우)

[describe]

- Qdlin(전압축 1,000포인트 방전 용량)으로 100번째와 10번째 사이클의 차이 $\Delta Q(V)$ 계산, 셀별 분산을 로그 변환
- $\log_{10}\text{var}(\Delta Q)$ vs $\log_{10}\text{cycle_life}$: $r = -0.846$ (Spearman -0.853) ↔ 초기 평균 QD $r = 0.19$


[plot]

- 단명 셀(빨강)일수록 ΔQ 곡선이 음의 방향으로 크게 휘고, 장수 셀(파랑)은 0 근처 → 초기 90사이클 동안 방전 특성이 많이 변한 셀일수록 수명이 짧음
- Q2에서 겹쳐 보이던 셀들이 ΔQ 곡선 형태로는 수명 순서대로 분리됨
- log-log 산점도에서 뚜렷한 음의 선형 관계. 좌상단 5점은 직선에서 이탈 → Q2의 EOL 미도달 셀과 일치


[to modeling]

- $\log_{10}\text{var}(\Delta Q)$ 를 **핵심 피쳐로 채택** (원논문 핵심 피쳐와 일치)
- 분산은 매우 작고 치우친 값 → 로그 변환으로 선형 관계 확보 → 타깃도 $\log_{10}(\text{cycle_life})$ 로 변환 시 선형 모델에 적합

Q4. 충전 조건(C-rate)과 수명의 관계는?



[그림 4] 충전 방식별 평균 수명 (± 1 std, n = 방식별 셀 수)



[그림 5] 충전 방식 문자열에서 추출한 1단계 C-rate(C1) · 2단계 C-rate(C2) vs 수명

[describe]

- 충전 방식(명목척도) 23종, 방식당 셀 1~3개 → 문자열에서 C1, 전환 시점(%), C2 수치 추출
- Spearman : C1 $p = -0.48$ ($p = 0.001$, 유의) / C2 $p = 0.05$ ($p = 0.754$, 유의하지 않음)


[plot]

- 고속 충전일수록 수명 감소 경향. 최하위 5.4C(80%)-5.4C(약 545)는 전 구간 고속, 반면 8C(15%)-3.6C는 최고 속도지만 15%만 고속 → 약 1,000 → **고속 충전 구간의 길이**가 함께 영향
- 상위 1~2위(4C(80%)-4C, 3.6C(80%)-3.6C, 총 5셀)는 EOL 미도달 셀과 일치
- 동일 방식 내 편차 존재 (4.8C(80%)-4.8C ± 165) → 셀 간 제조 편차

[to modeling]

- 방식명 Dummy 변환은 23개 컬럼 생성(셀 46개 대비 과다) → 수치 피쳐(C1 등)로 변환 검토
- 충전 조건만으로는 셀 편차 설명 불가 → 셀 고유 신호(ΔQ)와 결합 필요. 배치 간 일반화는 6장에서 검증

Q5. 상관관계 — 어떤 신호가 수명과 연관되어 있는가?



[그림 6] 초기 100사이클 피쳐 상관 히트맵 (원본 코드, cycle 1의 0값 포함 상태)

피쳐 (0값 제거 후)	log var(ΔQ)	충전시간	C1	평균온도	최고온도	IR	평균 QD	std QD
Spearman ρ vs 수명	-0.853	+0.641	-0.483	-0.371	-0.323	+0.189	+0.185	+0.051


[describe / plot]

- 수명과의 상관 순위 : ΔQ 분산 > 충전시간 > C1 > 온도 $\gg$ IR·QD (약함)
- 다중공선성 : 평균온도 $\leftrightarrow$ 최고온도 0.95
- 0값 제거 효과 : std_QD $\leftrightarrow$ mean_IR 0.47 $\rightarrow$ 0.02 (원본 관계는 위장 결측치가 만든 가짜 상관)

[to modeling]

- 핵심 : log var(ΔQ) / 보조 후보 : 충전시간, C1, 평균온도 / 용량·저항 평균은 예측력 약함
- 다중공선성 $\rightarrow$ 온도는 하나만 사용하거나 Ridge·Lasso 정규화로 제어

6. Batch 1 · 2 · 3 비교



[그림 7] 배치별 수명 분포(좌) · 배치별 $\log \text{var}(\Delta Q)$ vs $\log \text{cycle_life}$ (우)

항목	Batch 1 (학습)	Batch 2 (테스트)	Batch 3 (추가 테스트)
유효 셀 수 (수명 결측 제외)	46	39 (8개 제외)	44 (2개 제외)
수명 중앙값 / 범위	858 / 534~1,227	472 / 392~1,186	1,006 / 541~1,935
500 미만 비율	0%	71.8%	0%
1,000 초과 비율	21.7%	7.7%	52.3%
550 미만 (분류 라벨 0)	1개	30개	1개
ρ : $\log \text{var}(\Delta Q)$ vs 수명	-0.853	-0.716	-0.800
ρ : 충전시간 vs 수명	+0.641	-0.812	+0.261
ρ : 평균온도 vs 수명	-0.371	+0.166	+0.025
충전 방식 수 (Batch 1과 공통)	23종	12종 (2종)	8종 (0종)

- ① **분포 이동** : 테스트셋 Batch 2의 71.8%가 학습셋에 없던 500 미만 구간 → 학습 범위 밖 예측(외삽) 필요. Batch 3는 반대로 더 긴 수명 쪽으로 이동
- ② **일반화되는 신호** : $\log \text{var}(\Delta Q)$ 는 세 배치 모두 강한 음의 상관이며, 산점도에서 하나의 직선 위에 연결됨 (Batch 2는 우하단, Batch 3는 좌상단으로 연장)
- ③ **일반화되지 않는 신호** : 충전시간·온도는 배치마다 상관 부호가 바뀌고, 충전 방식도 거의 겹치지 않음 → Batch 1 실험 설계에 종속된 신호

7. 모델 설계 전략

7-1. Regression vs Classification → Regression 선택

판단 근거 (EDA 출처)	Regression (초기 100사이클)	Classification (초기 5사이클)
핵심 피처 $\Delta Q = Q_{100} - Q_{10}$ 사용 가능 여부 (Q3)	가능	불가 (5사이클까지만)
학습 클래스 균형 (Q1, 6장)	해당 없음	Batch 1 1:45, Batch 2 30:9로 정반대
피처-타겟 관계 (Q3)	log-log 선형 ($r = -0.85$)	—
ESS 활용 (교체 시점 계획)	잔여 수명 수치 제공	장/단 구분만

Target Variable : $\log_{10}(\text{cycle_life})$ — 예측 후 10^x 로 복원하여 MAPE 계산 (원논문 목표 9.1%)

7-2. Feature Engineering

구분	피처	근거
핵심	$\log_{10}\text{var}(\Delta Q(V))$	전 배치에서 안정적인 강한 상관 (Q3, 6장)
후보	$\log \min \Delta Q $, mean ΔQ , 초기 용량 변화량(기울기)	같은 ΔQ 곡선의 다른 요약 / Knee 이전의 미세 열화 (Q2) → 피처 선택으로 검증
주의	충전시간, C1, 온도	Batch 1 내 상관은 있으나 배치 간 부호 불일치 → 포함 시 Valid-Test Gap으로 검증
제외	최고온도, IR·QD 단순 평균	평균온도와 다중공선성 0.95 / 예측력 약함 (Q5)

전처리 : cycle 1의 0값·이상치 제거 후 계산, 스케일링은 학습셋에서만 fit (데이터 누수 방지)

7-3. Modeling Strategy

우선순위	후보 모델	선택 이유 (EDA 연결)
1순위	Linear Regression, Ridge, Lasso, ElasticNet	테스트셋 대부분이 학습 범위 밖(6장 ①) → 직선 관계를 연장할 수 있는 선형 모델이 외삽에 유리 / 셀 46개 소표본·다중공선성 → 정규화로 과적합 제어 (Q1, Q5)
2순위 (비교)	RandomForest, XGBoost, LightGBM	비선형(Knee) 패턴 확인용 베이스라인. 트리 모델은 학습 범위 밖을 예측하지 못하므로 Batch 2 Gap으로 한계 확인

- **검증** : Batch 1 내 셀 단위 Hold-out (동일 충전 방식 셀이 train/valid에 나뉘지 않도록 고려 — Q4), 테스트는 Batch 2 1회
- **데이터 처리** : EOL 미도달 의심 셀 5개 포함/제외 비교, 수명 결측 셀 제외
- **평가** : MAPE, Gap(Train-Valid / Valid-Test / Target-Test). Batch 3는 추가 검증(선택)

8. 한계 및 DAY 2 계획

- Q2 열화 곡선·Q4 방식별 비교는 Batch 1 중심으로 수행, 배치 비교는 수명 분포· ΔQ ·상관 지표로 수행
- EOL 미도달 의심 셀 5개의 실제 수명은 확인 필요 (원논문은 일부 셀을 다음 배치에서 이어서 측정한 것으로 알려짐)
- 충전 방식별 표본 1~3개 → 충전 조건 관련 해석은 경향성 수준
- DAY 2 : 7장 전략대로 파이프라인 구현 → 포맷에 맞춘 성능 리포트 및 Gap 해석